

# Основні означення: Optimization Theory

Vladyslav Skrynyk, Olena Mikhailova

19 березня 2025 р.

## 1 Основні означення

### 1.1 Опуклість (Convexity)

Функція  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  називається **опуклою**, якщо для всіх  $x, y \in \mathbb{R}^n$  і будь-якого  $\lambda \in [0, 1]$  виконується:

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y). \quad (1)$$

### 1.2 Сильна опуклість (Strong Convexity)

Якщо в (1) виконується строга нерівність.

### 1.3 L-smoothness

Функція  $f : \Omega \rightarrow \mathbb{R}$  є  $L$ -гладкою, якщо її градієнт є  $L$ -Ліпшицевим, тобто виконується нерівність

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2, \quad \forall x, y \in \Omega.$$

\*градієнт не змінюється надто критично\*

### 1.4 Лема спуску (Descent Lemma)

Нехай  $f : \Omega \rightarrow \mathbb{R}$  є  $L$ -гладкою на опуклій області  $\Omega$ . Тоді функцію  $f$  можна оцінити зверху наступним чином:

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2}\|y - x\|_2^2, \quad \forall x, y \in \Omega. \quad (2)$$

**Доведення.** Виразимо приріст  $f(y) - f(x)$  як інтеграл від градієнта уздовж прямої, що з'єднує  $x$  та  $y$ , а потім використаємо Ліпшицеву умову на градієнт  $\nabla f$  для оцінки приросту:

$$\begin{aligned} f(y) - f(x) &= \int_0^1 \langle \nabla f(x + t \cdot (y - x)), y - x \rangle dt \\ &= \left( \int_0^1 \langle \nabla f(x + t \cdot (y - x)) - \nabla f(x), y - x \rangle dt \right) + \langle \nabla f(x), y - x \rangle \\ &\leq \left( \int_0^1 \|\nabla f(x + t \cdot (y - x)) - \nabla f(x)\|_2 \cdot \|y - x\|_2 dt \right) + \langle \nabla f(x), y - x \rangle \\ &\leq \left( \int_0^1 tL\|y - x\|_2^2 dt \right) + \langle \nabla f(x), y - x \rangle \end{aligned}$$

$$= \frac{L}{2} \|y - x\|_2^2 + \langle \nabla f(x), y - x \rangle.$$

Перегрупувавши вирази, отримуємо твердження теореми.

**Теорема (Лема про градієнтний спуск, ДОДАТКОВА).** Нехай  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  є  $L$ -гладкою. Тоді для будь-якого  $0 < \eta \leq \frac{1}{L}$  кожен крок градієнтного спуску (1) гарантує:

$$f(x_{t+1}) \leq f(x_t) - \frac{\eta}{2} \|\nabla f(x_t)\|_2^2.$$

## 1.5 Розмір кроку (Stepsize, Learning rate)

Розмір кроку  $\alpha_k$  в ітераційному методі визначає, наскільки далеко ми рухаємося в напрямку градієнта:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k). \quad (1)$$

## 1.6 Градієнтний спуск (Gradient Descent)

Метод градієнтного спуску визначається рекурентним співвідношенням:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k), \quad (2)$$

де  $\alpha_k$  — це розмір кроку. Це ітераційний алгоритм оптимізації першого порядку, в якому для знаходження локального(глобального) мінімуму функції здійснюються кроки, пропорційні протилежному значенню градієнту функції в поточній точці.

## 1.7 Пошук вздовж прямої (Linesearch)

Метод визначення оптимального розміру кроку  $\alpha_k$  шляхом розв'язання задачі:

$$\alpha_k = \arg \min_{\alpha > 0} f(x_k - \alpha \nabla f(x_k)). \quad (3)$$

### 1.7.1 Exact Line-Search

Після вибору напрямку (у градієнтному спуску це напрямок негативного градієнта) можна розглянути таку одновірну задачу оптимізації для визначення найкращого розміру кроку:

$$\eta_t = \arg \min_{\eta \geq 0} f(x_t - \eta \nabla f(x_t)).$$

Часто вирішення цієї задачі точно є обчислювально складним, тому на практиці зазвичай використовують наближений підхід.

### 1.7.2 Backtracking Line-Search

Ідея методу зворотного відстеження (*backtracking line-search*) загалом полягає в тому, щоб спочатку спробувати агресивний (великий) розмір кроку та поступово зменшувати його, якщо він занадто великий.

Алгоритм працює наступним чином: ми вибираємо два параметри  $\alpha \in (0, 0.5)$  і  $\beta \in (0, 1)$ . На ітерації  $t$ :

1. Ініціалізуємо  $\eta = 1$ .

## 2. Перевірка умови: якщо

$$f(x_t - \eta \nabla f(x_t)) > f(x_t) - \alpha \eta \|\nabla f(x_t)\|_2^2,$$

тоді оновлюємо  $\eta := \beta \times \eta$  і повторюємо перевірку.

## 3. В іншому випадку робимо крок:

$$x_{t+1} = x_t - \eta \nabla f(x_t).$$

На практиці часто використовують значення  $\alpha = 0.3$  та  $\beta = 0.5$ , що дає непогані результати.

## 1.8 Метрична проекція (Metric Projection)

Метрична проекція точки  $x$  на опуклу множину  $C$  визначається як

$$P_C(x) = \arg \min_{y \in C} \|x - y\|. \quad (4)$$

## 1.9 Швидкість збіжності (Convergence Rate)

Швидкість збіжності методу оптимізації характеризує, як швидко послідовність  $\{x_k\}$  наближається до оптимального розв'язку  $x^*$ . Розглядають:

- Лінійну збіжність:  $\|x_k - x^*\| \leq Cq^k$ , де  $q \in (0, 1)$ .
- Квадратичну збіжність:  $\|x_{k+1} - x^*\| \leq C\|x_k - x^*\|^2$ .

### 1.9.1 Аналіз збіжності

Припустимо, що функція  $f$  є опуклою та диференційовною, її область визначення  $\text{dom}(f) = \mathbb{R}^n$ , а також градієнт  $\nabla f$  є Ліпшицевим з константою  $L > 0$ :

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2, \quad \forall x, y \in \mathbb{R}^n.$$

Або, якщо  $f$  двічі диференційовна:

$$\nabla^2 f(x) \preceq LI.$$

**Теорема:** Градієнтний спуск із фіксованим розміром кроку  $t \leq \frac{1}{L}$  задовольняє:

$$f(x^{(k)}) - f^* \leq \frac{\|x^{(0)} - x^*\|_2^2}{2tk}.$$

Аналогічний результат справедливий для методу зворотного відстеження, якщо замінити  $t$  на  $\frac{\beta}{L}$ .

Таким чином, градієнтний спуск має швидкість збіжності  $O(1/k)$

\*Для того щоб отримати  $f(x) - f(x^*) \leq \epsilon$  треба  $O(1/\epsilon)$  ітерацій\*